

Taller de R

Benjamín Muñoz

5 al 7 de Enero de 2017

1. Objetivo

El curso busca introducir a los alumnos en el lenguaje de programación R, abordando los contenidos esenciales para su utilización como usuario. Lo fundamental es lograr que los alumnos sean capaces de usar el software estadístico de manera autónoma, dominando los aspectos básicos y siendo capaces de consultar/investigar sobre el modo de utilizar las aplicaciones más avanzadas. Producto de lo anterior, se proponen como objetivos específicos:

- Conocer los principios de funcionamiento de R como “lenguaje” orientado a objetos, como software abierto y como interfaz con línea de comandos.
- Aprender los aspectos fundamentales de la sintaxis y operaciones básicas para la manipulación de objetos (con distintas estructuras).
- Introducir los conceptos básicos de elaboración de funciones y programación en R.
- Introducir buenas prácticas en el flujo de trabajo para el manejo de datos.
- Conocer como importar datos desde distintas fuentes.
- Realizar análisis descriptivos sencillos de un conjunto de datos con R.
- Conocer los comandos básicos para implementar técnicas de inferencia estadística.
- Introducir la noción de “reproducibilidad” y documentación de códigos y su relevancia en el trabajo empírico.
- Introducir el uso de paquetes para el trabajo con códigos dinámicos.

2. Metodología de Trabajo

El curso tiene una estructura de taller, utilizando R y R-Studio¹ y bases de datos reales para el desarrollo de actividades. Se enfatizará el uso de herramientas para la investigación reproducible (Markdown y Knitr).

Se recomienda que los alumnos asistan con un computador personal el cual tenga instalado R y R-Studio. En caso contrario, las instalaciones de la Escuela proporcionarán computadores para el desarrollo de las actividades prácticas.

¹Es probablemente el entorno de desarrollo integrado (IDE) asociado al lenguaje de R más utilizado.

3. Contenidos

1. Módulo 1: Introducción a R. **Jueves 5 de Enero,9:30-13:00**
 - a) Introducción: filosofía de R y su instalación.
 - b) Sintaxis: Operaciones aritméticas básicas.
 - c) Sintaxis: asignación y combinación.
 - d) Manejo de errores frecuentes y búsqueda de ayuda.
 - e) Estructura de datos: vectores, matrices, factores, marcos de datos y listas.
 - f) Funciones y paquetes en R.
 - g) Principios de programación (loops, familia apply y códigos propios).
2. Módulo 2: Importación y Manejo de Datos. **Jueves 5 de Enero,13:30-17:30**
 - a) Importación desde archivos planos (read.txt, read.csv, etc.).
 - b) Importación desde Excel.
 - c) Importación desde otros programas estadísticos: SPSS y Stata.
 - d) Exploración de datos brutos y filosofía “tidy”.
 - e) Manejo de datos con funciones básicas.
 - f) Manejo de datos con paquetes dplyr, stringr, reshape2, etc.
3. Módulo 3: Análisis Exploratorio de Datos. **Viernes 6 de Enero,9:30-13:00**
 - a) Comandos para estadística descriptiva básica.
 - b) Funciones para el cambio de unidad de análisis y agrupamiento de datos.
 - c) Generación de tablas.
 - d) Sistema de graficación en R.
 - e) Opciones avanzadas para gráficos.
4. Módulo 4: Estadística Inferencial. **Viernes 6 de Enero,13:30-18:00**
 - a) Comandos para el trabajo con variables aleatorias.
 - b) Inferencia clásica: test de hipótesis e intervalos de confianza.
 - c) Análisis de regresión lineal (MCO).
5. Módulo 5: Investigación Reproducible. **Sábado 7 de Enero,10:00-13:30**
 - Principios y buenas prácticas.
 - Documentación de scripts.
 - Investigación Reproducible: uso de Markdown y Knitr.

4. Bibliografía

Hay una infinidad de manuales de R² de altísima calidad. Acá se incluyen algunas referencias útiles:

Referencias

- Cotton, R. (2015). *Learning r. a step-by-step function guide to data analysis*. (1st Edition ed.). O'Reilly.
- Fox, J., y Weisberg, S. (2012). *An r companion to applied regression*. SAGE.
- Gandrud, C. (2015). *Reproducible research with r and rstudio* (2nd Edition ed.). CRC Press.
- Heiss, F. (2016). *Using r for introductory econometrics*.
- Kabacoff, R. (2015). *R in action: Data analysis and graphics with r* (2nd Edition ed.). Manning Publications.
- Monogan, J. (2016). *Political analysis using r* (1st Edition ed.). Springer.
- Peng, R. (2015). *Report writing for data science in r*. Leanpub.
- Peng, R. (2016a). *Exploratory data analysis with r*. Leanpub.
- Peng, R. (2016b). *R programming for data science*. Leanpub.
- van der Loo, M. P., y de Jonge, E. (2012). *Learning rstudio for r statistical computing*. Packt Publishing.
- Wickham, H. (2016). *ggplot2. elegant graphics for data analysis* (2nd Edition ed.). Springer.
- Wickham, H., y Golemund, G. (2016). *R for data science*. O'Reilly.
- Xie, Y. (2015). *Dynamic documents with r and knitr* (2nd Edition ed.). CRC Press.

4.1. Lecturas Sugeridas

Lo único necesario para el curso-taller es ganas de aprender y acceso a un computador e internet. No son necesarias lecturas previas para el curso. De todos modos, acá les sugiero algunas lecturas (disponibles en el Drive de la Escuela) que pueden servir para repasar los contenidos y utilizar R en sus propios proyectos:

1. Módulo 1: Introducción a R.

- Kabacoff, R. (2015). *R in Action: Data Analysis and Graphics with R* **Capítulos 1 y 2, pgs. 3-45**. Sencilla introducción de R como software y lenguaje, con una buena explicación de las estructuras de datos.
- Cotton, R. (2013). *Learning R* **Capítulos 1 al 5, pgs. 13-78**. Introducción sistemática a los tipos de datos y a las operaciones fundamentales en R.
- van der Loo, M. & deJonge, E. (2012). *Learning RStudio for R Statistical Computing* **Capítulos 1 y 2, pgs. 5-41**. Un tanto antiguo, pero muy buena introducción a las ventajas de Rstudio y sobre cómo usarlo.

²También existen otras herramientas de aprendizaje, tales como foros de discusión, blogs, MOOCs y documentos gratuitos.

2. Módulo 2: Importación y manejo de datos en R.

- Kabacoff, R. (2015). *R in Action: Data Analysis and Graphics with R* **Capítulos 4 y 5, pgs. 71-113**. Avanza progresivamente desde la definición de variables hasta operaciones más complejas relativas a la estructura de datos. De todos modos, contiene algunos temas (p. ej. sobre SQL) que no les resultarán muy relevantes.
- Monogan, J. (2016). *Political Analysis Using R* **Capítulo 2, pgs. 13-32**. Es un panorama aplicado de una sesión de manejo de datos típica en ciencias sociales.
- Cotton, R. (2013). *Learning R* **Capítulos 12 y 13, pgs. 169-206**. Presenta una amplia gama de funciones para el manejo de datos.
- Wickham, Hadley. (2014). *Tidy Data*. Journal of Statistical Software. Es una excelente introducción a la filosofía “tidy” para el manejo de datos.
- Wickham, Hadley. (2014). *ggplot2: Elegant graphics for data analysis*. 2nd. Edition **Capítulos 9 y 10, pgs. 189-220**. Explicación bien desarrollada de cómo utilizar la filosofía tidy en proyectos empíricos.

3. Módulo 3: Análisis exploratorio de datos en R.

- Peng, R. (2015). *Exploratory Data Analysis with R*. **Completo**. Sintético repaso de todos los elementos de la descripción de datos.
- Kabacoff, R. (2015). *R in Action: Data Analysis and Graphics with R* **Capítulos 3, 6 y 7, pgs. 46-70; 117-174**. Todo lo necesario para el trabajo con R de estadística descriptiva.
- Monogan, J. (2016). *Political Analysis Using R* **Capítulos 3 y 4, pgs. 33-62**. Muestra como se usan las funciones básicas para la exploración de datos.

4. Módulo 4: Estadística inferencial en R.

- Kabacoff, R. (2015). *R in Action: Data Analysis and Graphics with R* **Capítulo 8, pgs. 167-211**. Buen repaso del uso de regresión en R. Para expandir el trabajo en este campo, el manual de Fox y Weisberg es excelente, no obstante su antigüedad.
- Monogan, J. (2016). *Political Analysis Using R* **Capítulos 5 y 6, pgs. 63-96**. Condensa muchos temas en pocas páginas, de todos modos existen manuales especializados según el tema que deseen trabajar. Pueden consultarme por fuentes específicas para distintos temas.

5. Módulo 5: Investigación Reproducible con R.

- van der Loo, M. & deJonge, E. (2012). *Learning RStudio for R Statistical Computing* **Capítulo 5, pgs. 75-491**. Breve introducción al uso de RStudio y la generación de reportes que integran código y texto.

- Peng, R. (2015). *Report Writing for Data Science in R*. **Texto completo**. Es una buena introducción a la generación de reportes dinámicos con una perspectiva amplia.
- Kabacoff, R. (2015). *R in Action: Data Analysis and Graphics with R* **Capítulo 22, pgs. 513-531**. Muy amena la introducción al uso de documentos dinámicos en R, con distintas plataformas. Si les interesa el tema, el texto de Xie (2015) o el de Granddud (2015) son fundamentales.