

Taller de R

Módulo 3: Análisis Exploratorio de Datos

Benjamín Muñoz

6 de Enero

Escuela de Verano de Métodos Mixtos 2017

Tabla de Contenidos

1. Repaso
2. Estadística Descriptiva
3. Manejo de Datos para el cálculo de indicadores
4. Generación de Tablas
5. Gráficos: aspectos básicos
6. Comandos avanzados de gráficos

Repaso

Repaso 1

- Durante el primer día nos centramos en los aspectos básicos del uso de R. En el primer módulo revisamos las características básicas del software (instalación de R, Rstudio y de paquetes; actualización).
- Luego revisamos las operaciones básicas para el trabajo empírico: operaciones aritméticas (R como calculadora), asignación (`<-`), combinación (`c()`) e indexación (`[i]`).
- Por último, revisamos los tipos atómicos de objetos (character, numeric, integer, complex, logical) , otras versiones (factores, valores perdidos). También las estructuras de datos básicas: vector, matriz, marco de datos y lista.

Repaso 2

- En el segundo módulo analizamos los principios básicos del análisis empírico en R. Primero revisamos el concepto de espacio de trabajo y cómo optimizarlo.
- Luego, revisamos algunas funciones básicas para inspeccionar objetos en R. Ejemplos de dichas funciones son: `View()`, `summary()`, `names()`, `attributes()` y `class()`.
- También revisamos la importación de datos a R: formato `.RData`, archivos de texto (`.txt`, `.csv` archivo separado por comas), libros de Excel (`.xls` o `.xlsx`) y otros paquetes estadísticos (`.dta` y `.sav`).
- Finalmente vimos algunas operaciones con bases de datos: agregar casos (`rbind`), agregar variables (`merge`), redimensionar datos (`subset`) y cambiar la unidad de observación (`aggregate`).

Estadística Descriptiva

- R es un software orientado a objetos: todo es un objeto en el espacio de trabajo, desde un número a una base de datos que tenga todas las cuentas activas de Facebook (1.79 billones).

Manejo de Datos para el cálculo de indicadores

Recodificación de Variables

- Existen una multiplicidad de funciones para recodificar variables, adaptándose a distintas tareas que deseen realizarse.
- La recomendación principal es **recodificar en una nueva variable**. Si se realiza sobre la variable original, se pierde la información original.
- Dado que trabajamos con múltiples objetos en el espacio de trabajo, es necesario asignar la nueva variable a la base de datos deseada. Un error frecuente que pueden encontrar son las diferencias en dimensiones de ésta.

Procedimiento de Recodificación

- `base$var_recodificada <- comando_recodificación(base$var_original)`

Transformaciones básicas

- **Transformación Lineal:**

- `base$var_rec01 <- base$var_orig + 5`
- `base$var_rec01 <- base$var_orig / 3`

- **Otras Transformaciones:**

- `base$var_rec01 <- sqrt(base$var_orig)`
- `base$var_rec01 <- log(base$var_orig)`
- `base$var_rec01 <- (base$var_orig01 + base$var_orig02)/2`
- `base$var_rec01 <- round(base$var_orig, digits = 5)`

Transformaciones Especiales

- **Paquete Scales:** reescalar fijando el mínimo y máximo.
- `base$var_rec01 <- scales::rescale(base$var_orig, to=c(mín, máx))`
- **Paquete Hmisc:** generar cuantiles y otros grupos de interés.
- `base$var_rec01 <- cut2(base$var_orig, cuts, m, g, levels.mean, digits, minmax=TRUE, oneval=TRUE, onlycuts=FALSE)`
- Permite tres tipos de transformaciones a una variable continua. Con `cuts=c(a,b,...)` se fijan puntos de corte.
- Con `m=número` se fija el mínimo de observaciones requeridas en cada grupo.
- Con `g=número` se fija el número de cuantiles (grupos a generar).

Transformaciones Especiales 2

- **Paquete Hmisc: imputación básica:** reemplazar los valores perdidos (NA's) por válidos.
- **Por un número específico:**
 - `base$var_rec01 <- impute(base$var_orig, 4)`
- **Por un número al azar:**
 - `base$var_rec01 <- impute(base$var_orig, 'random')`
- **Por una función de resumen:**
 - `base$var_rec01 <- impute(base$var_orig, mean)`
- **Paquete Hmisc: rezagos**
 - **Lag:** `base$var_rec01 <- Lag(base$var_orig, shift = 1)`
 - **Lead:** `base$var_rec01 <- Lag(base$var_orig, shift = -2)`

Transformaciones Especiales 3

- **Paquete sjmisc: transformaciones z**
- **Centrar por la media:** resta el promedio (nueva media es 0).
 - `base$var_rec01 < -center(base$var_orig)`
- **Estandarización:**
 - `base$var_rec01 < -std(base$var_orig)`
- **Paquete sjmisc: dicotomización**
 - `base$var_rec01 < - dicho(base$var_orig, dich.by='criterio')`
 - Por defecto, dicotomiza por la mediana (`dich.by="median"`), pero también es posible hacerlo por la media (`dich.by="mean"`).

Recodificación de Valores

- **Paquete car: función recode**
- `base$var_rec01 <- car::recode(base$var_orig,
 ‘‘valores_originales= nuevos_valores ’’)`
- Dentro de las doble comillas se fijan las reglas de asignación. Si se trata de caracteres (texto) se usan comillas simples para señalarlas. Los criterios se separan por puntos y coma (;).
- Se puede usar el argumento `else` para asignar un valor a todos los restantes no señalizados (debe ir al final).
- Es posible agrupar valores con `c()`, de modo de darles a varios valores originales un único valor recodificado.

Generación de Tablas

Gráficos: aspectos básicos

Comandos avanzados de gráficos
