

Taller de R

Módulo 5: Investigación Reproducible

Benjamín Muñoz

7 de Enero

Escuela de Verano de Métodos Mixtos 2017

Tabla de Contenidos

1. Investigación reproducible: principios
2. Documentación de scripts y buenas prácticas
3. Uso de Markdown

Investigación reproducible: principios

- De manera sencilla es buscar que el proceso científico pueda ser evaluado de manera más completa y entendida como un flujo.
- La presentación de resultados es sólo la punta del iceberg. La idea es exponer el flujo de trabajo -a lo menos el empírico. Tiene limitaciones al trabajar fuera de enfoques cuantitativos.
- **Reproducibilidad computacional** se basa en la provisión de un código y detalles de implementación. Por otra parte, la **empírica** busca que exista información detallada sobre las observaciones y la tarea empírica (recolección de datos). Por último, la **estadística** requiere proveer información detallada sobre la selección de modelos estadísticos, modelos, transformaciones, ajustes, etc.

- Se documenta de manera completa y adecuada un código y se provee para que la audiencia audite el procedimiento computacional, reproduzca independiente los resultados y los pueda aplicar a nuevos problemas.
- Tiene como supuesto la existencia de un esquema lógico para el análisis empírico.

- Organización del análisis
 - Transparencia
 - Mejores prácticas
 - Scripts procesados por sobre de códigos brutos
-
- **Mismos datos y mismos scripts dan el mismo resultado presentado.** Este es el mínimo de repetibilidad.

¿Por qué buscar reproducibilidad

- Demostrar que tus resultados son correctos y se fundamentan en un adecuado flujo de trabajo.
- Tu audiencia cuenta con código y datos que demuestran cuáles son las decisiones que generan los resultados expuestos y permiten su justificación y análisis crítico.
- Otro aspecto es que permite que otros se nutran de tus métodos, lógicas de trabajo y resultados (Acumulación de conocimiento).

Documentación de scripts y buenas prácticas

- La idea de código reproducible es que otros usuarios puedan recrear tus resultados (positivos o negativos). Al hacer pasos relevantes del análisis por medio de Menú se pierde reproducibilidad (todo en el script). Otro aspecto importante es la documentación y control de las versiones.
- Es necesario, como mínimo, que el código incluya:
 1. Paquetes requeridos.
 2. Datos utilizados.
 3. Código pertinente.
 4. Descripción del ambiente de R en uso.

- Indicar paquetes al inicio del script.
- Es importante poner a disposición los datos. A veces es imposible proveer los datos. Buscar versiones en línea de los datos o generar un pequeño ejemplo (sea con valores simulados o ingresados).
- El paso central es depurar el código para que otros puedan entender lo que haces.
- Utilizar elementos gráficos: indentar el código, separar líneas, etc. Los nombres de las variables -y objetos en general- son concisos e informativos.
- Usar comentarios para señalar aspectos importantes.
- La mejor prueba es abrir una nueva sesión de R y reproducir con el script.
- El proceso de analizar datos brutos es reportado y preservado (mantienen datos originales).

- Mantener archivos utilizados en directorios relacionados y adecuadamente nombrados. Explicitar el directorio de trabajo usado.
- Los nombres de las variables y etiquetas son también legibles (minúscula, alfanumérico, sin símbolos problemáticos por encoding). Ideal es que no sea difícil determinar de que son las variables.
- Documentar los valores perdidos e indicar sus fuentes.
- Código incorpora título y subtítulos. Entre estos aspectos es útil incluir el nombre del autor, del proyecto y una sección de objetivos.
- Si el código es demasiado extenso, puede ser preferible estructurarlo en distintas tareas y usar un esquema de código-maestro. Usar nombres adecuados para los archivos de código.

Codigo para Presentar Problemas

- Aprovecha los comentarios para señalar dónde se encuentra explícitamente el problema.
- Simplifica el problema: busca el código menos extenso para reproducir el problema analizado.
- Incluye el output de `sessionInfo()` como comentario para describir el ambiente de R.

Uso de Markdown

- Markdown es un lenguaje simple para el trabajo. En R permite la generación de códigos dinámicos y reproducibles.
- Permite combinar un código ejecutable y un reporte de resultados para una audiencia determinada.

- En R se necesita instalar el paquete `rmarkdown`. También el paquete `knitr`
- En RStudio se pueden utilizar plantillas predeterminadas de RMarkdown. Tienen una extensión `.Rmd`.
 - Se puede incluir un encabezado con `- - -`
 - El código de R se rode de `""`.
 - El texto se escribe simplemente y existen reglas sencillas de formateo.



- Son piezas de código identificadas de modo tal para que sean ejecutadas por R:
 - Van separadas por los delimitadores `""r` y `""`.
 - Se pueden crear también por Menú o por medio del teclado en RStudio (Windows: `Ctrl+Alt+I`/ OS X: `Cmd+Alt+I`)

- Evaluar código: eval: (TRUE; logical) si evaluar o no.
- Colapsar código collapse: (FALSE; logical) si se puede colapsar o sintetizar el código en su expresión.
- Inclusión Resultado include :(logical) señala si se incluye en el archivo final.
- Inclusión Código: echo: (TRUE; logical or numeric) si incluir el código (se puede indicar las líneas).
- Mensaje: message = (logical) si se incluyen o no los mensajes en el documento.
- Advertencias: warning = (logical) si se incluyen o no las advertencias.
- fig.cap = "...." adds a caption to graphical results.
- <https://yihui.name/knitr/options/>

- Se puede incluir código dentro del texto por medio 'r '. Al interior de este separador se incluye el código. No se cuentan con las opciones previas, pero permite presentar el resultado del código dentro del texto.
- No lo utilizaremos, pero se pueden fijar parámetros generales para la selección de objetos.
- La función `knitr::kable` permite presentar tablas con un mejor formato.
- El título se incluye en el preámbulo.
- Para variar entre títulos y subtítulos se usa el símbolo #. Mientras más se incluyan menor el tamaño.

Otros elementos en Markdown

- El énfasis se hace por medio de símbolos:
 - `_itálica_`
 - `__negrita__`
- Las listas se hacen por medio `*` o números.
- Un link por medio de paréntesis `[] ()`.
- Imágenes por medio de `![alt-text](locación)`

- <https://www.rstudio.com/wp-content/uploads/2015/02/rmarkdown.pdf>
- <https://guides.github.com/features/mastering-markdown/>
- <https://github.com/adam-p/markdown-here/wiki/Markdown-Cheats>